

Wahrnehmungsstrukturen von Patient_innen im Kontext stationärer Gesundheitsversorgung in Deutschland

Merlin Reinhardt

März 2025 *

Zusammenfassung

Ortsbezogene Online-Rezensionen stellen einen wertvollen Forschungsgegenstand dar, um über sozio-geografischen Erfahrungen und Wahrnehmungen zu erfahren. In dieser Arbeit werden sie genutzt, um Wahrnehmungsmuster in Bezug auf Krankenhäuser und andere Gesundheitseinrichtungen zu identifizieren. Im Vergleich verschiedener Topic Modelling-Ansätze zeigt sich, dass nicht primär fachlich-klinische Aspekte thematisiert werden, sondern insbesondere interpersonelle, organisatorische und andere strukturelle Faktoren, welche Patient_innen für ein relatives Wohlbefinden im Krankenhaus wichtig sind.

*Hausarbeit im Forschungspraktikum 'Computational Social Science' im Wintersemester 2024/25 bei Dr. Christian Czymara an der Goethe-Universität Frankfurt am Main im Rahmen des Master of Arts Soziologie.

Inhaltsverzeichnis

1	Einleitung	4
2	Hintergrund und Forschungsstand	4
2.1	Spannungsfeld Krankenhaus	4
2.2	Soziologisches Potential von Online-Rezensionen und Topic Modelling . .	6
3	Daten und Methoden	7
3.1	Krankenhausverzeichnis und Google-Maps: Abruf und Validierung der Daten	7
3.2	Analyseverfahren: Natural Language Processing und Topic Modelling . .	9
4	Ergebnisse	11
4.1	Überblick und Modellvergleich mit STM und BERTopic	11
4.2	Detailanalyse mit BERTopic: Geführtes Modell und Ein-Sterne-Modell	14
5	Diskussion und Fazit	14
A	Zusätzliche Daten	19
B	Weiteres Material	27

Abbildungsverzeichnis

1	STM bei $k = 9$: Erwartete Themenanteile bei einer Rezension	13
2	Länge der Rezensionstexte nach Zeichen	20
3	Gesamtbewertungen der Krankenhäuser	20
4	STM mit unterschiedlicher Anzahl an Topics: Exklusivität der Themen und Semantische Cohärenz	21

Tabellenverzeichnis

1	Potentielle Konfliktauslöser im klinischen Umfeld	6
2	Ergebnisse der manuellen Validierung einer Stichprobe von 100 Rezensionen	9
3	Verwendete Sprachrepräsentationsmodelle mit Programmiersprache & cha- rakteristische Eigenschaften	10
4	Anzahl der Rezensionsbewertungen nach Sternebewertung	12
5	Anzahl an Rezensionen nach Bundesländern	21
6	Anzahl an Rezensionen nach Art des Trägers	21
7	STM, $k = 9$	22

8	BERTopic-Modell (k=30): Themenübersicht.	23
9	Vergleich: Themenübersicht STM (k=9) und BERTopic (k=30)	24
10	Top 21 Themen des Guided BERTopic Modells	25
11	Top 19 Themen des Ein-Sterne-BERTopic Modells	26

1 Einleitung

Krankenhäuser sind nicht nur Orte medizinischer Behandlung, sondern durch die vulnerable Situation der Patient_innen und eine starre und hierarchisierte soziale Rollenverteilung Räume mit ausgeprägtem Potential für prägende Erfahrungen sowie der Entstehung von Konflikten. Desweiteren kondensieren sich gesellschaftliche Herausforderungen wie Fachkräftemangel, demografischer Wandel und hohe Arbeitsbelastung in Krankenhäusern in besonderem Maße. Die vorliegende Hausarbeit beschäftigt sich mit dem Erleben von Patient_innen und artikulierten Herausforderungen aus Patient_innenperspektive im Kontext stationärer Gesundheitsversorgung in Deutschland.

Inhaltlich sollen folgende Fragestellungen untersucht werden: Was ist Patient_innen im Kontext stationärer Gesundheitsversorgung wichtig? Welche Wahrnehmungsmuster gibt es? Was beschäftigt sie in Bezug auf den Aufenthalt? Wie Patient_innenzentriert fühlt sich der Aufenthalt an einem Ort an, welcher genau diesen Grundanspruch erheben sollte? Um diese Fragen explorativ und offen zu untersuchen, verfolgt die Arbeit den Ansatz, Patient_innenerfahrungen lebensweltnah zu beziehen. Google Maps, einst als Kartendienst entstanden, mittlerweile ein weitverbreitetes sozio-geografisches Erfahrungs- und Wahrnehmungsabbild, sowie digitaler Austausch-, Diskussions- und Mitteilungsraum, bietet durch offene Thematisierungsmöglichkeiten dafür eine ideale Basis: Im Rahmen dieser Arbeit gelingt es, zu 87 Prozent aller Krankenhäuser und Kliniken in Deutschland insgesamt mehr als elftausend Rezensionen abzurufen und mittels zwei verschiedener Topic-Modelling-Ansätze umfangreiche Einblicke in ortsbezogene Wahrnehmungs- und Erlebensmuster von Patient_innen zu erlangen.

Angewandte Methoden basieren auf dem Forschungspraktikum von Christian Czymara im Wintersemester 2025/26 an der Goethe-Universität, sowie dem Buch 'Communicational Analysis of Communication' von Van Atteveldt et al. (2022). Da diese Arbeit im Kontext eines Methodenseminars stattfindet, werden bei der Umsetzung zwei verschiedene Modelle für Topic Modelling angewendet, um deren Funktionsweisen und Eigenheiten in einer praktischen Anwendung in Bezug auf Rezensionen zu vertiefen. Nach einem kurzgehaltenen Modellvergleich basiert die Hauptanalyse auf dem BERTopic Modell von Grootendorst (2022).

2 Hintergrund und Forschungsstand

2.1 Spannungsfeld Krankenhaus

Krankenhäuser als emotional stark aufgeladene Orte bei gleichzeitig hoch ausgeprägtem Hierarchisierungsgrad und einer klaren Rollenverteilung zwischen Personal und Patient_innen bieten per Definition ein soziales Spannungsfeld mit ausgeprägtem Konfliktpo-

tential: die subjektiv gerechtfertigten hohen Erwartungen der Patient_innen, oft begleitet von Sorgen, Ängsten und einer physischen und psychischen Ausnahmesituation, treffen auf Personal, welches sich unter schwierigen Arbeitsbedingungen, wie beispielsweise einer hohen Arbeitsdichte und Personalmangel dem Druck ausgesetzt sieht, diesen Erwartungen gerecht zu werden, während es sich, je nach Personalstruktur, in stetigen zeitlichen Abwägungsprozessen gefangen sieht (Neander, 2024, S. 1-2).

Verbale Konflikte bis hin zu Gewalterfahrungen im Krankenhaussetting sind kein neues Phänomen (Estryn-Behar et al., 2008, S. 107-109). Sowohl im öffentlichen Diskurs als auch in der Fachliteratur wird jedoch weiterhin von einem hohen Niveau, teils auch von einem Anstieg von Konflikten im Kontext stationärer Gesundheitsversorgung, insbesondere jedoch nicht ausschließlich im Bereich akuten Notfallversorgung, berichtet und die Gründe dafür diskutiert. Teilen von Patient_innen wird ein aggressives Verhalten attestiert und die Austragungsebene der Konflikte reicht dabei von verbal bis physischen Aggressionen, von welchen zwischen 19 und 36% der Mitarbeitenden im Gesundheitssystem berichten (Alsharari et al., 2022, S. 48). Weiterführendes hierzu in Bass et al. (2024), Lübbers (2015) und Alsharari et al. (2022), Kayser and Kaplan (2020).

Krankenhäuser als Teil eines ökonomisierten Gesundheitssystems haben bei aller Wirkmächtigkeit ökonomischer Faktoren das Ziel, die Patient_innenorientierung als wichtiges Qualitätskriterium für den Versorgungsmaßstab heranzuziehen. Die Erfassung von Patient_innenbedürfnissen, -erfahrungen und -bewertungen ist einerseits zentral für die Evaluation und Entwicklung behandlungsspezifischer Aspekte (Dehn-Hindenbergh, 2010, S. 399) und bietet darüber hinaus Möglichkeiten, als Qualitätsindikator für strukturelle Zustände in der Gesundheitsversorgung zu dienen.

In der Forschung wurden diverse konfliktbegünstigende Faktoren identifiziert. Darunter fallen sowohl klinische als auch nicht-klinische Aspekte: in der Literatur genannt werden strukturelle Faktoren der Einrichtung, wie eine dünne Personaldecke und eine hohe Arbeitsbelastung, jedoch auch sozialstrukturelle, kulturelle, kommunikative oder interpersonelle Faktoren, wie geringes Vertrauen seitens Patient_innen gegenüber dem Personal und Grad der Patient_innenzentriertheit (Estryn-Behar et al. (2008, S. 110); Alsharari et al. (2022, S. 50); Neander (2024, S. 2)). Ein ausdifferenzierter theoretischer Ausgangspunkt stellt die Matrix der Konfliktauslöser in Bergman (2015) und Kayser and Kaplan (2020) dar, nachzuvollziehen in Tabelle 1.

Da Konflikte als Folge mangelnder Bedürfniserfüllungsmöglichkeiten und als Ergebnis von Bedrohungsgefühlen angesehen werden können, lohnt es sich genau hinzuschauen, welche Themen Patient_innen beschäftigen, was sie positiv bewerten und negatives berichten, kurzum, was ihnen wichtig ist. Denn trotz bestehenden Wissens ist im Bereich weitere innovative Forschung nötig (Bass et al., 2024, S. 1114).

Tabelle 1: Potentielle Konfliktauslöser im klinischen Umfeld

Kommunikation, Info., Emotionen, Empathie	Familiendynamik	Vorurteile/ Stereotypen
Gesundheits- disparitäten	Kulturelle Diff, EOL Streitigkeiten, Ziele-Werte	Misstrauen gegenüber Medizinsystem
Chronische Krankheit	Meinungs- verschiedenheiten der Betreuungs- personen	Fragwürdige Richtlinien

Anmerkung: Die Matrix zeigt bekannte Auslöser, die zur Analyse von Konflikten im Krankenhauskontext herangezogen werden können. Adaptiert von Kayser and Kaplan (2020, S. 1351) nach Bergman (2015). Abkürzungen: Info.=Information, Diff=Differenz, EOL=Lebensende.

2.2 Soziologisches Potential von Online-Rezensionen und Topic Modelling

Die Nutzung von großen, unstrukturierten Textmengen für soziologische Forschung scheiterte über viele Jahre hinweg an technischer Umsetzbarkeit. In diesem Punkt ist seit einigen Jahren eine große Veränderung zu beobachten. Bei gleichzeitiger Weiterentwicklung der methodischen Möglichkeiten steigt die rechnerische Leistung während die Kosten zur Nutzung der technischen Infrastruktur für den Umgang mit großen Datensätzen immer seltener ein echtes Hindernis darstellen (Alexander et al. (2022, S. 2), Van Atteveldt et al. (2022, Kapitel 1.1)). Dies bietet Möglichkeiten für die Untersuchung neuer Fragestellungen und die Verarbeitung offenerer, destandardisierter Datenquellen, wie etwa unstandardisierte Mitteilungen über ihre Erfahrungen von Patient_innen im digitalen Raum. Entgegen weit verbreiteten Zweifeln, Rezensionen seien durch starke Verzerrungen im Nutzerverhalten als Datenquelle ungeeignet (Alexander et al., 2022, S. 2), scheint ein Rückgriff auf Erfahrungen von Patient_innen durchaus lohnenswert. So ermittelte Greaves et al. (2012) einen positiven Zusammenhang zwischen der Online-Krankenhausbewertungen von Patient_innen und objektiven Qualitätsbewertungskriterien wie Infektionsraten und Sterblichkeit (Greaves et al., 2012, S. 435). Während einerseits Untersuchungen in Bezug der Patient_innenerfahrungen lange überwiegend auf postalischen Fragebögen basierten, werden andererseits die Chancen offener Antwortmöglichkeiten von vielen Autor_innen betont (Gleeson et al., 2016, S. 4).

Da Patient_innen als Experten in Bezug auf ihr Erleben im Krankenhaus zu betrachten sind, sind solche Erfahrungserkenntnisse immer auch als Indikator für eine Zielerfüll-

lung des Gesundheitssystems zu betrachten.

Während die Nutzung von Online-Rezensionen als Datenquelle bereits in Kontexten der Wirtschaftswissenschaften (Vallurupalli and Bose (2020), Eckart (2021)), der Tourismusforschung (Rossetti et al. (2016), Park et al. (2020)), der Linguistik (Wagenknecht, 2022) und Informatik (Gryka and Janicki, 2023), um einige exemplarische Studien zu nennen, Anwendung findet, scheinen im Bereich der Gesundheitssystemforschung die Potentiale noch unausgeschöpft¹.

3 Daten und Methoden

3.1 Krankenhausverzeichnis und Google-Maps: Abruf und Validierung der Daten

Die Datengrundlage dieser Arbeit bildet sich aus zwei zentralen Quellen: Einerseits dem öffentlich zugänglichen Krankenhausverzeichnis der statistischen Bundes- und Landesämter (Statistische Ämter des Bundes und der Länder, 2025), welches alle Krankenhäuser-, Reha- und Vorsorgeeinrichtungen in Deutschland aus dem Jahr 2023 verzeichnet. Außerdem wurde die Google Maps Place API, eine Programmierschnittstelle genutzt, um in Form von abgerufenen Online-Rezensionen die inhaltliche Grundlage für die Untersuchung der Patient_innenerfahrungen zu schaffen (Google Maps, 2025). Google Maps wurde aufgrund des hohen Vebreitungsgrades und der dadurch hohen Anzahl an abrufbaren Rezensionen im Vergleich mit anderen Dienstleistern ausgewählt.

Die beiden Datenquellen wurden kombiniert, sodass ein umfassender Datensatz mit den Texten der Google Maps Rezensionen von 11782 Google Maps Nutzer_innen, einschließlich der Sterne-Bewertung, zu 2438 Krankenhäusern, Kliniken und Gesundheitseinrichtungen in Deutschland mit diversen ortspezifischen Informationen wie der durchschnittlichen Bewertung auf Google Maps, der Bettenzahl, des Trägers, der Versorgungsstufe und des Versorgungstypus entstand. Für die Analyse mit dem Topic-Modell BER-Topic (Kapitel 3.2) wurden die Rezensionen aufgrund ihrer unterschiedlichen Länge in einzelne Sätze unterteilt, wodurch ein Datenkorpus mit 86717 Dokumenten entstand.

Eine zentrale Herausforderung der Arbeit bestand in dem dreischrittigen Abruf der Google Maps Daten. Jedem in Google Maps verzeichneten Ort ist eine sogenannte 'place_id'

¹Anmerkung: An dieser Stelle sei auf eine Studie von Bhukya and Sheshikala (2023) verwiesen. Mit dem Titel "NLP based Topic Modeling for Healthcare: Analyzing Patient Reviews to Improve Quality of Care and Access to Services" scheint die Studie einen sehr ähnlichen Ansatz wie die vorliegende Arbeit zu verfolgen: LDA-basiertes Topic-Modelling in Bezug auf Patient_innenrezensionen. Bei näherem Hinsehen wirkte die Arbeit in Bezug auf ihre Wissenschaftlichkeit und Durchführung jedoch unglaublich unwürdig. Die Existenz angegebener Literatur konnte trotz Recherche nicht in Erfahrung gebracht werden, die tatsächliche Datengrundlage blieb unklar und der Fließtext hinterließ aufgrund eines oberflächlichen, allgemeingehaltenen Scheibstiles, sowie aufgrund vieler inhaltlicher Wiederholungen den Eindruck einer zumindest teilweise maschinellen, unwissenschaftlichen Genese.

zugeordnet, welche für den API-Abruf benötigt wird. In einem ersten Schritt wurden iterativ die `place_id`'s für jeden im Krankenhausverzeichnis verzeichneten Standort ermittelt. Anhand der `place_id`'s folgte der Abruf der Rezensionen einschließlich der Sternebewertung und einer Zeitangabe, welche sich auf die Erstellung der Rezensionen bezog. Es wurden pro `place_id` fünf Abrufe getätigt, da dies der Maximalanzahl an zugelassenen Abrufen pro Ort entspricht. Da eine zufällige Auswahl der abzurufenden Rezensionen durch Google Maps nicht vorgesehen ist, entschied die API selbst, welche Rezensionen ausgegeben wurden. Die Ausgabe erfolgte dabei nach der selben Reihenfolge, nach welcher die Rezensionen auch auf der Web-Version von Google Maps angezeigt werden. Es ist davon auszugehen, dass die Auswahl der Rezensionen von Google-internen Kriterien beeinflusst ist, welche nach einer angenommenen 'Relevanz für die Nutzer_innen' orientiert. In einem dritten Schritt wurde die durchschnittliche Ortsbewertung mittels API abgerufen und dem Datensatz ebenfalls beigelegt.

In Deutschland gab es im Jahr 2023 1874 Krankenhäuser an 2776 Standorten mit 476 924 Betten (Statistische Ämter des Bundes und der Länder, 2025). Mit 2438 abgerufenen Krankenhausstandorten sind über 87% der Standorte im für diese Arbeit entwickelten Datensatz abgebildet. Auf den gesamten Datensatz bezogen liegt das arithmetische Mittel an Rezensionen pro Krankenhaus bei 4,83, wodurch die ortsbezogene Stichprobe an Rezensionen nur in Ausnahmefällen weniger als fünf beträgt. Die 11782 Rezensionen sind im arithmetischen Mittel 662 Zeichen lang (für die genaue Längenverteilung siehe Abbildung 2).

Die Validierung der automatisierten Abrufe wurde durch die manuelle Kodierung einer randomisierten Stichprobe von 100 Rezensionen durchgeführt. Die Fehlertoleranz wurde vorab auf maximal fünf Prozent festgelegt. Kontrollkriterien waren die Plausibilität des Ortes des Krankenhausverzeichnisses und des Google Maps Abrufes, sowie ob die Rezension auch in der Webversion von Google Maps zu finden war. Die manuelle Validierung wurde am 13.03.2025 durchgeführt. Wie in Tabelle 2 dargestellt wurden 98 Prozent der Rezensionen der Stichprobe für valide oder eingeschränkt valide eingestuft. Zwei Rezensionen waren jedoch nicht in der Webversion von Google Maps auffindbar und wurden als invalide gekennzeichnet. Bei den drei Rezensionen, welche als 'eingeschränkt valide' kodiert wurden, bestand zwar eine Plausibilität des Ortes und der Rezensionen, jedoch ab es Adresskonflikte zwischen der Angabe auf Google Maps und der Angabe im Krankenhausregister. Mit einer Invalidität von zwei Prozent entspricht die Stichprobe somit der vorab festgelegten Fehlertoleranz.

Zu Erwähnen ist außerdem, dass es bei größeren Kliniken häufig mehrere Repräsentationen des Klinikums auf Google Maps gab, beispielsweise in Form des 'Gesamtklinikums' und einzelner 'Stationen' oder 'Versorgungsbereiche'. Da in Bezug auf diese Arbeit jedoch ohnehin kein Anspruch auf eine vollständige Rezensionsrepräsentation erhoben wird, liegt keine Einschränkung der Aussagekraft dieser Arbeit vor.

Tabelle 2: Ergebnisse der manuellen Validierung einer Stichprobe von 100 Rezensionen

Kategorie	Anzahl	Prozent
Valide	95	95.00%
Eingeschränkt valide	3	3.00%
Invalide	2	2.00%

3.2 Analyseverfahren: Natural Language Processing und Topic Modelling

Methodisch ist diese Arbeit dem übergeordneten Feld des Natural Language Processing (NLP) anzusiedeln, worunter auch die in dieser Arbeit genutzten Ansätze des Topic Modelling einzuordnen sind. Im NLP wird anhand informatischer Modelle und Methoden versucht, verschiedene Aufgaben in Zusammenhang mit menschlicher Sprache computerbasiert zu bearbeiten. Während für die Alltagsnutzung eine Beispielapplikation eine Übersetzungs-App sein könnte (Lauriola et al., 2022, S. 443-444), finden im Bereich der Sozialwissenschaften Methoden wie etwa automatisierte Textklassifizierungen zum Beispiel im Rahmen einer Sentiment Analyse oder wie im Falle dieser Arbeit Topic Modelle zur Analyse von Diskursen eine Anwendung (Van Atteveldt et al., 2022, Kapitel 11.4).

Topic Modelle haben in den vergangenen Jahren nicht nur in den Sozialwissenschaften verstärkt Verwendung gefunden. Hierbei handelt es sich um eine Form der unüberwachten Textanalyse (Unsupervised Text Analysis), wobei Wörter und Dokumente in abstrakte 'Themen' gruppiert werden. Anhand Beobachtungen gemeinsamen Auftretens von Wörtern wird, ähnlich wie bei einer Regressionsanalyse, versucht, ein numerisches Abbild der Textstruktur zu erschaffen, womit der Textkorpus bei einer möglichst minimalen Fehlerrate rekonstruiert werden könnte. Die Themen werden anschließend mittels eines numerischen Clustering-Prinzips entwickelt (Van Atteveldt et al., 2022, Kapitel 11.5).

In der detaillierten Umsetzung der Repräsentation und des Clusterings unterscheiden sich die einzelnen Modelle jedoch stark. In den letzten Jahrzehnten weitverbreitet und als Fundament anderer Topic Modelle zu begreifen, ist die Latent Dirichlet Allocation (LDA) von Blei et al. (2003). Weiterentwicklungen davon sind Structural Topic Models (STM) von Roberts et al. (2019) und Bi-Term Topic Models (BTM) von Wijffels et al. (2020). Für einen guten Überblick über die Pakete in R siehe (Wiedemann, 2022, p. 288). In dieser Arbeit werden 'Structural Topic Modelling' (STM) Roberts et al. (2019) sowie BERTopic Grootendorst (2022) genutzt (Tabelle 3).

Die Methode der Latent Dirichlet Allocation ist ein stochastisch-generatives Modell, welches davon ausgeht, dass Dokumente aus einer Mischung von Themen bestehen und jedes Wort in einem Dokument aus einem dieser Themen stammt. Durch die Analyse der Wortverteilungen in einer Sammlung von Dokumenten, versucht LDA die zugrunde liegenden Themen zu clustern und identifizieren, die diese Dokumente erzeugt haben könnten.

Dabei wird die 'Bag-of-words'-Annahme getroffen, welche Mögliche Bedeutungen semantischer Beziehungen ausklammert, und die Anordnung von Wörtern als irrelevant begreift. Das Clustering geschieht nach der Annahme, dass ähnliche Themen aus ähnlichen Wörtern bestehen müssen (Van Atteveldt et al., 2022, Kapitel 11.5.1). Das Structural Topic Modelling basiert auf LDA, bietet aber die Möglichkeit, strukturelle Kovariaten in das Modell miteinzubeziehen (Van Atteveldt et al., 2022, Kapitel 11.5.5). Da der Datensatz dieser Arbeit ebensolche Kovariaten beinhaltet, wird für den ersten Teil der Analyse die STM in der Programmiersprache R genutzt.

Eine fundamentale Chance zur Weiterentwicklung im Bereich des Topic Modelling stellt die numerische Repräsentation von Texten mittels vortrainierter Sprachrepräsentationsmodelle wie BERT dar (Devlin et al., 2019). BERT, eine Abkürzung für Bidirectional Encoder Representations from Transformers, weicht im Gegensatz zu den beschriebenen herkömmlichen Sprachrepräsentationsmodellen von der 'Bag-of-Words'-Annahme ab, sondern bezieht gleichzeitig die Wörter links und rechts des betrachteten Wortes mit ein, wodurch semantische Beziehungen auf Satz- und Textebene im Repräsentationsmodell mit abgebildet werden. Der Textkorpus wird so in eine vektorisierter Form überführt, bei welchem die einzelnen Begriffe und entsprechend der jeweiligen räumlichen Anordnung auch ihre Beziehung zueinander in multidimensionaler Vektorform gelingt (Devlin et al., 2019, S. 4171-4174). Sowohl in der Methode der LDA als auch in BERT können Dokumenten mehrere Themen zugeordnet werden.

Eine praktische Umsetzung des BERT-Prinzips im Bereich des Topic Modellings, stellt das BERTopic Paket von Grootendorst (2022) dar. In BERTopic wird die Textrepräsentationsmöglichkeit von BERT mit einer Dimensionalitätsreduktion für einen optimierten Clustering-Prozess und einer Topic-Extraktion mittels einer angepassten Form der TF-IDF-Methode² kombiniert (Grootendorst, 2022, S. 2-3). Da BERTopic eine semantiktreue Repräsentation bietet und gegenüber LDA-basierten Modellen als leistungsfähiger gilt (Grootendorst, 2022), basiert der Hauptteil der Analyse dieser Arbeit auf BERTopic-Modellen. Die Nutzung von BERTopic erfolgt in der Programmiersprache Python.

Tabelle 3: Verwendete Sprachrepräsentationsmodelle mit Programmiersprache & charakteristische Eigenschaften

Structural TM (R)	Bag-of-Words; Kovariaten werden miteinbezogen
BERTopic (Python)	Semantische Repräsentation; geringes Pre-Processing

Die **Datenaufbereitung** ist je nach verwendeter Methode unterschiedlich aufwändig. Während BERTopic in der Lage ist, originalgetreue Textdaten zu sinnvoll zu verarbeiten, ist bei LDA-basierten Methoden eine umfangreiche Datenaufbereitung erforderlich.

²Die TF-IDF-Methode kombiniert die zwei Statistiken 'Term-Frequency' und 'Inverse-Document-Frequency' miteinander. Dadurch kann die Wichtigkeit und Aussagekraft eines Begriffes innerhalb einzelner Beiträge eines Textkorpus ermittelt werden (Grootendorst (2022, S. 3); Joachims et al. (1997)).

Hierbei ist das Ziel, Wörter zu für eine bessere Bezugnahme zu Standardisieren und die zu verarbeitende Datenmenge zu reduzieren. (Van Atteveldt et al., 2022, Kapitel 9). Im Rahmen dieser Arbeit wurden in Vorbereitung für das STM Großschreibung in Kleinschreibung umgewandelt, Stopwörter, Satzzeichen und Wortendungen entfernt und Begriffe auf ihren Wortstamm reduziert (Denny and Spirling, 2018, S. 170-171). Da die Daten insgesamt in einem sehr gutem Zustand von Google Maps übermittelt wurden, wurden die Rezensionen für die BERTopic-Analyse lediglich in einzelne Sätze zerlegt, um prägnantere Dokumente zu erzeugen.

Ein die Ergebnisse stark beeinflussender Faktor ist die **Anzahl der Themen**, nach denen geclustert werden soll. Während BERTopic standardmäßig die Anzahl an zu erstellenden Themen selbst herausarbeitet, muss bei LDA-basierten Verfahren, wie dem STM, die Anzahl der Themen vorab festgelegt werden (Roberts et al., 2019, S.10-13, 34-35). Im Rahmen der Arbeit wurden aus diesem Grund sechs verschiedene STM-Modelle mit unterschiedlichen festgelegten Themenanzahlen (K) berechnet und auf Basis der Ergebnisse (Abbildung 4) eine Abwägung zwischen semantischer Kohärenz und Exklusivität der Themen getroffen. Die Anzahl der Themen wurde mit $K = 9$ festgelegt.

In Kontrast zu STM ist bei BERTopic die Anzahl der zu extrahierenden Themen nicht von Anfang an festgelegt. Dennoch gilt es auch hier, eine Abwägung zu finden: Themen sollen nicht zu speziell sein, sondern einen übertragbaren Erkenntnisgewinn mit sich bringen, während sie ebenfalls nicht zu allgemein oder oberflächlich gehalten sein sollen. Im Rahmen dieser Arbeit wurde deshalb ein iterativer Ansatz gewählt. Im Anschluss an die Generierung eines 'freien' Modells, welches selbstständig über 800 Themen herausarbeitete, wurde dieses in einem Clusteringprozess mit $k = 30$, $k = 20$ und $k = 15$ in der Dimensionalität reduziert. Die zentrale methodische Entscheidung ist hierbei, dass für die Analyse das $k = 30$ Modell gewählt wurde, da es trotz eines gesteigerten Detaillgrads dennoch übersichtlich bleibt. Die Validierung erfolgte primär durch eine qualitative Inhaltsanalyse, bei der die thematische Kohärenz und Interpretierbarkeit der Themen anhand unter Rückbezug auf Beispieltex te bewertet wurde.

Nach erster Datenbegutachtung wurden ferner zwei weitere Modelle trainiert: ein 'Guided' Modell, bei welchem zu bereits explorierten Themen Stichwörter als Anknüpfungspunkte definiert wurden, sowie ein Modell, welches ausschließlich die Ein-Sterne-Rezensionen modellierte.

4 Ergebnisse

4.1 Überblick und Modellvergleich mit STM und BERTopic

Die Anzahl der abgerufenen Rezensionen spiegelt die Größe der Bundesländer nach Einwohnerzahl wider, wie in Tabelle 5 abgebildet. Von den 11782 Rezensionen entfällt au-

ßerdem circa jeweils ein Drittel auf eine öffentliche (4213 Rezensionen), private (3974 Rezensionen) oder freigemeinnützige (3595 Rezensionen) Trägerschaft (Tabelle 6). Die abgerufenen Rezensionen sind in Bezug auf ihre Sterne-Bewertung tendentiell an den Rändern zu verorten. So bilden Fünf-Sterne-Bewertungen (Anzahl: 7135) und Ein-Sterne-Bewertungen (Anzahl: 3054) über 86 Prozent der Gesamtbewertungen, während Zwei-, Drei- und Vier-Sterne-Bewertungen unterrepräsentiert sind (Tabelle 4). Ob dies an einem höheren Mitteilungsbedürfnis bei stark positiven oder negativen Wahrnehmungen oder an der Rezensionspräsentation seitens Google Maps liegt, ist uneindeutig.

Tabelle 4: Anzahl der Rezensionsbewertungen nach Sternbewertung

1 Stern	2 Sterne	3 Sterne	4 Sterne	5 Sterne
3054	473	379	741	7135

Durch die kombinierte Anwendung der zwei unterschiedlichen Topic-Modeling-Ansätze, STM mit $k = 9$ und BERTopic mit $k = 30$, zeigen sich robuste Muster in der Wahrnehmung der Krankenhausaufenthalte von Patient_innen. Die Ergebnisse der beiden Modelle sind für das STM-Modell in Tabelle 7 und Abbildung 1 und für BERTopic in Tabelle 8 dargestellt. Eine vergleichende Themenübersicht ist in Tabelle 9 herausgearbeitet.

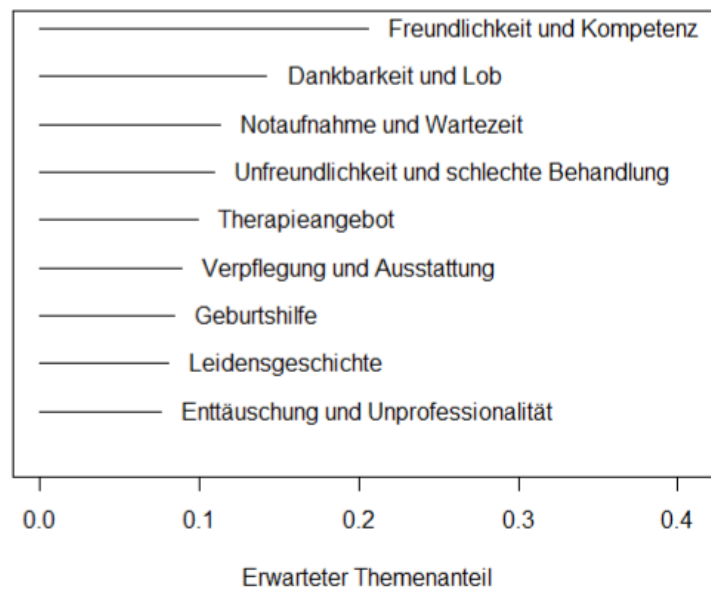
Ein von beiden Ansätzen identifiziertes Themenfeld betrifft die zwischenmenschliche Interaktion zwischen Patient_innen und Krankenhauspersonal. Wie in Abbildung 1 zu erkennen, heben mehrere der STM-Themen (Un-)Freundlichkeit und eine subjektiv wahrgenommene schlechte Behandlung hervor. Dieser Eindruck wird durch das BERTopic-Modell unterstützt: vier der 30 Themen befassen sich dezidiert mit 'Freundlichkeit', 'Umgang' (Tabelle 8). Ebenso kristallisiert sich die hilfsbedürftige Rolle, in welcher Patient_innen sich in der Regel unfreiwillig befinden, aus: Hilfsbereitschaft wird vielfach positiv betont. Patient_innen sind im Krankenhauskontext per Definition in ihrer Selbstständigkeit eingeschränkt und haben das starke Bedürfnis gesehen und als Individuen ernstgenommen zu werden.

Neben interpersonalen Faktoren sind organisatorische Faktoren zentral. Wartezeiten, insbesondere in der Notaufnahme, sowie Terminkoordination, telefonische Erreichbarkeit, und Zeitmanagement sind Themen, welche in beiden Modellen als relevant identifiziert werden.

Neben der menschlichen Komponente spielen die Rahmenbedingungen wie die physische Umgebung, die Ausstattung, Hygiene sowie Annehmlichkeiten des täglichen Lebens eine wichtige Rolle: Sauberkeit, abwechslungsreiches Essen, eine Essensauswahl, Parkplätze, WLAN, die Zimmerausstattung und -atmosphäre sind in beiden Modellen wiederkehrende Diskussionspunkte.

Aspekte der medizinischen Versorgung werden durch diverse Themen repräsentiert. Neben Evaluierung des Therapieangebotes und Mitteilung von Erfahrungen in Bezug auf

Abbildung 1: STM bei $k = 9$: Erwartete Themenanteile bei einer Rezension



die medizinische Behandlung, schildern Rezensionsschreiber_innen Diagnosen und ihre persönliche Leidensgeschichte.

Gleichzeitig nehmen Patient_innen eine Erfüllung ebendieser Faktoren in einem positiven Sinne nicht für Selbstverständlich: Themen, in welchen 'Dankbarkeit' und 'Lob' ausgedrückt wird, machen in beiden Modellen zentrale Bestandteile aus.

Neben den genannten gemeinsamen Befunden der beiden Modelle, gibt es nuancierte Unterschiede. Die Auseinandersetzung mit Themen der Geburtshilfe ist im STM-Modell sehr prägnant, während sie im BERTopic-Modell nicht prominent abgebildet wird. Dennoch arbeiten sowohl das Structural Topic Model als auch der BERTopic-Model, trotz ihrer unterschiedlichen Logik, wesentliche Themen ähnlich heraus und spiegeln die gesamte Bandbreite der Patient_innenerfahrungen wider.

Die Rezensionen bilden somit einen Teil der aus der Literatur erarbeiteten Konfliktauslöserthemen ab (Tabelle 1). Während Beiträge in Bezug auf Kommunikation, Empathie, Informationsmanagement, Streitigkeiten und chronische Krankheiten, sowie Beschwerden über subjektiv fragwürdige Richtlinien in beiden Modellen prominent abgebildet werden, und in diversen Rezensionen auch ein Misstrauen gegenüber der Gesundheitssystemorganisation mitschwingt, scheinen Themen bezüglich Gesundheitsdisparitäten, Familiendynamiken und Stereotypen im Gegensatz zur Literatur (Kayser and Kaplan, 2020) unterrepräsentiert.

4.2 Detailanalyse mit BERTopic: Geführtes Modell und Ein-Sterne-Modell

Neben den rein explorativen Modellen wurde zusätzlich ein geführtes Themenmodell trainiert. Hierbei wurden aufgrund der bereits explorierten Daten verschiedene thematische Schlüsselwörter³ eingebaut und somit eine thematischer Impuls in Richtung mit Blick auf die Fragestellung zentralere Themen eingebaut. Da das geführte Themenmodell auf den inhaltlich interpretierbaren Themen der offenen Modelle beruhte, wurden ähnliche Themen isoliert, welche jedoch insgesamt kohärenter und detaillierter waren (Tabelle 10). Durch die eingebauten Schlüsselwörter konnte außerdem das Thema 'Schmerzerfahrung/-behandlung' nun klarer herausgearbeitet werden, welches in den anderen Modellen zwar mehrfach auftrat, jedoch nie als eigenes Thema einklassifiziert wurde.

Um die spezifischen Kritikpunkte von besonders unzufriedenen Patient_innen zu erarbeiten, wurde abschließend noch ein BERTopic-Modell trainiert, welches sich ausschließlich auf die 'Ein-Sterne-Bewertungen' bezieht. Als Hauptgründe für extreme Unzufriedenheit konnten teils bekannte, teils ergänzende Themenpunkte isoliert werden (Tabelle 11): Eine zentrale Stellung des menschlichen Miteinanders auf die Zufriedenheit ist auch hier zu beobachten. Themen, welche sich auf den Umgang, das Personal, das 'sich ernst genommen fühlen' und eine würdevolle Behandlungen beziehen, werden in mehr als einem Drittel der insgesamt 3054 Ein-Sterne-Rezensionen thematisiert. Neben allgemeinen, unspezifischen Aussagen über die Klinik oder die Stationen spielen außerdem auch hier organisatorische Faktoren, wie telefonische Erreichbarkeit und Terminprobleme eine zentrale Rolle. Als strukturelle Herausforderung wird 'Personalmangel' benannt. In Kontrast zu den 'offenen' Modellen wird explizit das Thema 'Geld' und damit verbundene, subjektiv wahrgenommene Gesundheitsdisparitäten benannt (Tabelle 1). Auf medizinisch-fachlicher Ebene werden Fehldiagnosen, Medikationsentscheidungen und ein zu geringer Stellenwert des Genesung attestiert. Außerdem stellt auch hier das Essen ein wichtigen Diskussionspunkt dar.

5 Diskussion und Fazit

Die zentralen Herausforderungen und der Fokus dieser Arbeit lagen auf der Datengewinnung und der Anwendung und Exploration der verschiedenen Topic Modelling Ansätze. Im explorativen Ansatz konnten modellübergreifend und auf umfassender Datengrundla-

³Liste der ausgewählten Schlüsselwörter: freundlich, empathisch, kümmern, nett, kompetent, professionell, fachlich, diagnose, behandlung, untersuchung, station, ablauf, organisation, op, narkose, sauber, hygiene, putzen, reinigung, zimmer, bett, bad, ausstattung, wlan, essen, mahlzeiten, küche, cafeteria, getränke, schmerzen, schmerzmittel, übelkeit, beschwerden, information, kommunikation, gespräch, aufklärung, zufrieden, unzufrieden, empfehlen, weiterempfehlen, positiv, negativ, katastrophe, danke, dankeschön, dank

ge beruhende robuste Themenfelder entwickelt werden, welche in erster Linie verschiedene Facetten zwischenmenschlicher Umgangsweisen und organisatorischer Dimension sind, und medizinisch-fachliche Aspekte ebenfalls prominent und dennoch nachgeordnet sind.

Literatur

- Alexander, G., Bahja, M., Butt, G. F., et al. (2022). Automating large-scale health care service feedback analysis: sentiment analysis and topic modeling study. *JMIR medical informatics*, 10(4):e29385.
- Alsharari, A. F., Abu-Snieneh, H. M., Abuadas, F. H., Elsabagh, N. E., Althobaity, A., Alshammari, F. F., Alshmemri, M. S., Aroury, A. M., Alkhadam, A. Q., and Alatawi, S. S. (2022). Workplace violence towards emergency nurses: a cross-sectional multicenter study. *Australasian emergency care*, 25(1):48–54.
- Bass, G. A., Chang, C. W., Winkle, J. M., Cecconi, M., Kudchadkar, S. R., Akuamoah-Boateng, K., Einav, S., Duffy, C. C., Hidalgo, J., Rodriguez-Vega, G. M., et al. (2024). In-hospital violence and its impact on critical care practitioners. *Critical care medicine*, 52(7):1113–1126.
- Bergman, E. J. (2015). Identifying sources of clinical conflict: a tool for practice and training in bioethics mediation. *The Journal of clinical ethics*, 26(4):315–323.
- Bhukya, B. and Sheshikala, M. (2023). Nlp based topic modeling for healthcare: Analyzing patient reviews to improve quality of care and access to services. In *2023 International Conference on Emerging Techniques in Computational Intelligence (ICETCI)*, pages 7–12. IEEE.
- Blei, D. M., Ng, A. Y., and Jordan, M. I. (2003). Latent dirichlet allocation. *Journal of machine Learning research*, 3(Jan):993–1022.
- Dehn-Hindenbergh, A. (2010). Versorgungsqualität aus der nutzerperspektive: Der einfluss von alter und geschlecht auf die bedürfnisse von patienten im kontext patientenorientierter interaktion. *Das Gesundheitswesen*, 72(07):399–403.
- Denny, M. J. and Spirling, A. (2018). Text preprocessing for unsupervised learning: Why it matters, when it misleads, and what to do about it. *Political analysis*, 26(2):168–189.
- Devlin, J., Chang, M.-W., Lee, K., and Toutanova, K. (2019). Bert: Pre-training of deep bidirectional transformers for language understanding. In *Proceedings of the 2019 conference of the North American chapter of the association for computational linguistics: human language technologies, volume 1 (long and short papers)*, pages 4171–4186.
- Eckart, L. (2021). *Theoretische Konzeption und Analyse positiv emotionaler Online-Rezensionen am Beispiel der Nachkaufphase*. PhD thesis, Dissertation, Freiberg, TU Bergakademie Freiberg, 2021.

- Estryn-Behar, M., Van Der Heijden, B., Camerino, D., Fry, C., Le Nezet, O., Conway, P. M., and Hasselhorn, H.-M. (2008). Violence risks in nursing—results from the european ‘next’ study. *Occupational medicine*, 58(2):107–114.
- Gleeson, H., Calderon, A., Swami, V., Deighton, J., Wolpert, M., and Edbrooke-Childs, J. (2016). Systematic review of approaches to using patient experience data for quality improvement in healthcare settings. *BMJ open*, 6(8):e011907.
- Google Maps (2025). Google places api data. Daten abgerufen via API. Daten abgerufen am 11.03.2025. Der spezifische Datensatz hängt von der verwendeten Abfrage ab.
- Greaves, F., Pape, U. J., King, D., Darzi, A., Majeed, A., Wachter, R. M., and Millett, C. (2012). Associations between web-based patient ratings and objective measures of hospital quality. *Archives of internal medicine*, 172(5):435–436.
- Grootendorst, M. (2022). Bertopic: Neural topic modeling with a class-based tf-idf procedure. *arXiv preprint arXiv:2203.05794*.
- Gryka, P. and Janicki, A. (2023). Detecting fake reviews in google maps—a case study. *Applied Sciences*, 13(10):6331.
- Joachims, T. et al. (1997). A probabilistic analysis of the rocchio algorithm with tfidf for text categorization. In *ICML*, volume 97, pages 143–151. Citeseer.
- Kayser, J. B. and Kaplan, L. J. (2020). Conflict management in the ICU. *Critical Care Medicine*, 48(9):1349–1357.
- Lauriola, I., Lavelli, A., and Aiolfi, F. (2022). An introduction to deep learning in natural language processing: Models, techniques, and tools. *Neurocomputing*, 470:443–456.
- Lübbers, A. (2015). Aufnahme in Not. *Heilberufe*, 67(9):42–43.
- Neander, K.-D. (2024). *Konflikte Im Krankenhaus*. Springer.
- Park, E., Chae, B., and Kwon, J. (2020). The structural topic model for online review analysis: comparison between green and non-green restaurants. *Journal of Hospitality and Tourism Technology*, 11(1):1–17.
- Roberts, M. E., Stewart, B. M., and Tingley, D. (2019). Stm: An r package for structural topic models. *Journal of statistical software*, 91:1–40.
- Rossetti, M., Stella, F., and Zanker, M. (2016). Analyzing user reviews in tourism with topic models. *Information Technology & Tourism*, 16:5–21.

- Statistische Ämter des Bundes und der Länder (2025). Verzeichnis der krankenhäuser und vorsorge- oder rehabilitationseinrichtungen in deutschland. Krankenhausverzeichnis, Statistisches Bundesamt (Destatis), Wiesbaden. Stand: 31.12.2023.
- Vallurupalli, V. and Bose, I. (2020). Exploring thematic composition of online reviews: A topic modeling approach. *Electronic Markets*, 30:791–804.
- Van Atteveldt, W., Trilling, D., and Calderon, C. A. (2022). *Computational analysis of communication*. John Wiley & Sons.
- Wagenknecht, A. (2022). „trotzdem sollte man als metalfan dieses album besitzen.“online-rezensionen auf amazon als form der fankommunikation. *Fankulturen und Fankommunikation*, pages 177–198.
- Wiedemann, G. (2022). The world of topic modeling in r. *M&K Medien & Kommunikationswissenschaft*, 70(3):286–291.
- Wijffels, J., Yan, X., Guo, J., Lan, Y., and Cheng, X. (2020). Btm: Biterm topic models for short text. URL: <https://CRAN.R-project.org/package=BTM>. R package version 0.3, 1.

A Zusätzliche Daten

Abbildung 2: Länge der Rezensionstexte nach Zeichen




Abbildung 3: Gesamtbewertungen der Krankenhäuser




Tabelle 5: Anzahl an Rezensionen nach Bundesländern

Bundesland	Anzahl der Krankenhausrezensionen
Nordrhein-Westfalen	2347
Bayern	2065
Baden-Württemberg	1432
Niedersachsen	1002
Hessen	994
Rheinland-Pfalz	582
Schleswig-Holstein	570
Berlin	493
Sachsen	458
Brandenburg	422
Thüringen	355
Hamburg	318
Sachsen-Anhalt	311
Mecklenburg-Vorpommern	249
Saarland	114
Bremen	70
Gesamt	11782

Tabelle 6: Anzahl an Rezensionen nach Art des Trägers

Art des Trägers	Anzahl
öffentlicher Träger	4213
privater Träger	3974
freigemeinnütziger Träger	3595

Abbildung 4: STM mit unterschiedlicher Anzahl an Topics: Exklusivität der Themen und Semantische Cohärenz




Tabelle 7: STM, k = 9

Leidensgeschichte	Verpflegung und Ausstattung	Unfreundlichkeit und schlechte Behandlung
leid jahr wurd hatt lang mehr probl meinung dam diagnos angeht gesagt aggression ansah gemobbt hornhaut ruiniert stigmatisier medikament schlimm	essen zimm fruhstuck auswahl cafeteria parkplatz park wlan abwechslungsreich	termin frech telefon garnicht bock sitzt unfreundl katastroph frechheit antwort #schandfleck #nichtzuempfehl #schaemteuch
Notaufnahme und Wartezeit	Geburtshilfe	Dankbarkeit und Lob
notaufnahm stund tag schmerzmittel blut fieb krankenwag bauchschmerz geschickt rontg krankenhaus 100jahrig	dr op operation frau hebamm geburt kreissaal eingriff kaiserschnitt entbund	dank team klinik herzlich betreu dankeschon hervorrag bedank
Freundlichkeit und Kompetenz	Enttäuschung und Unprofessionalität	Therapieangebot
gut freundlich station sup ärzte nett hilfsbereit zuvorkomm top graz limburg lindau nachkomm supernett superschnell vollbring aufgehob kompetent	leid personal enttausch abrat unprofessionell schmutzig inakzeptabel beleid desinteressiert unfreund respektlos ignoriert verhalt	gut therapeut therapi konzept einzelgesprach psychotherapeut them kunsttherapi einlasst #keepyourheadup #mentalhealthcar gruppentherapi mitpatient therapieangebot

Tabelle 8: BERTopic-Modell (k=30): Themenübersicht.

Topic-ID	Themenbereich (interpretativ)	Beispielwörter	In ... Rezensionen
0	unspezifisch 1	nicht, kann, man, einfach, überhaupt, leider	11198
1	Patientenumgang	patienten, patient, umgang, behandelt, mensch, respekt	7834
2	Freundlichkeit 1	freundlich, sehr, alle, mitarbeiter, nett, hilfsbereit	6871
3	Notaufnahme	notaufnahme, schmerzen, wartezeit, stunden, triage, unfreundlich	6767
4	Gefühl: Gesehen worden	aufgehoben, gefühlt, gut, sicher, wohl, ernst	5797
5	Klinik Empfehlung	klinik, empfehlen, weiterempfehlen, diese, tagesklinik, gute	5169
6	Erfahrungen Station	station, stationär, schwestern, pflege, team, aufenthalt	4542
7	Gebäude	krankenhaus, dieses, gebäude, modern, sauber, alt	4442
8	Medizinische Behandlung	behandlung, medizinisch, therapie, op, arzt, diagnose	3783
9	Dank/Lob 1	dank, vielen, danke, großes, lob, dankeschön	3758
10	Personal 1	team, schwestern, gesamte, pflegeteam, ärzteam, super	3442
11	Personal 2	pflegepersonal, ärzte, pfleger, kompetent, freundlich, hilfsbereit	3255
12	Zeitmanagement	termin, wartezeit, stunden, minuten, lang, termine	2949
13	Tagesklinik	tag, tagesklinik, tage, tagen, wochen, aufenthalt	2705
14	Ausstattung	zimmer, sauber, toilette, bad, bett, modern	2412
15	Freundlichkeit und Kompetenz	personal, freundlich, kompetent, hilfsbereit, nett, gesamte	2360
16	Essen/Verpflegung	essen, lecker, gut, auswahl, mittagessen, frühstück	2228
17	Zeitpunkt des Aufenthalts	gewesen, 2024, 2023, uhr, datum, monate	1926
18	Bewertung 1	sterne, stern, atmosphäre, geben, vergeben, verdient	1258
19	Bewertung 2	grüße, grüßen, liebe, nie, wieder, schade	1034
20	Dank/Lob 2	vielen, dank, danke, dafür, alles, empfehlenswert	593
21	unspezifisch 2	bm, dumm, –, –, –, –	587
22	Dank/Lob 3	danke, weiter, dafür, so, macht, dankbar	418
23	Starke Negativbewertung	katastrophe, absolute, katastrophal, reinste, zustände, chaotisch	362
24	Freundlichkeit 2	lächeln, gesicht, freundlich, immer, lippen, influenza	300
25	Dank/Lob 4	danke, bravo, 1000, minus, dankeschön, top	204
26	unspezifisch 3	danke, punkt, anm, done, fyi, amen	193
27	unspezifisch 4	hh, what, ok, was, ihre, ps	124
28	Satzzeichen	!, !!, !!!, ???, –, –	120
29	unspezifisch 5	vielen, dank, jahrzehntelange, elisa, flügel, roland	87

Tabelle 9: Vergleich: Themenübersicht STM (k=9) und BERTopic (k=30)

STM Topic (k=9)	STM Keywords	Entsprechende BERTopic Themen (k=30, IDs & Interpretation)
Leidensgeschichte	leid, jahr, wurd, diagnos, hatt, schlimm	8 (Med. Behandlung), 17 (Zeitpunkt)
Verpflegung und Ausstattung	essen, zimm, fruhstuck, parkplatz, cafeteria, wlan	14 (Ausstattung), 16 (Essen/Verpflegung), 7 (Gebäude)
Unfreundlichkeit & schlechte Behandlung	termin, frech, telefon, unfreundl, katastroph, antwort	12 (Zeitmanagement), 19 (Bewertung 2), 23 (Starke Negativbew.), 3 (Notaufnahme - neg.)
Notaufnahme & Wartezeit	notaufnahm, stund, tag, schmerzmittel, blut, krankenhaus	3 (Notaufnahme), 12 (Zeitmanagement)
Geburtshilfe	dr, op, hebamm, geburt, kreissaal, kaiserschnitt	—
Dankbarkeit und Lob	dank, team, klinik, herzlich, betreu, dankeschon	9, 20, 22, 25 (Dank/Lob 1-4), 10, 11 (Personal 1-2), 4 (Gesehen worden)
Freundlichkeit & Kompetenz	gut, freundlich, station, sup, ärzte, nett, kompetent	2, 24 (Freundlichkeit 1-2), 4 (Gefühl: Gesehen worden), 6 (Erfahrung Station), 11 (Personal 2), 15 (Freundl./Komp.), 10 (Personal 1)
Enttäuschung und Unprofessionalität	leid, personal, enttausch, unprofessionell, schmutzig, respektlos	0 (unspezifisch 1), 15 (Freundl./Komp. - neg.), 19 (Bewertung 2 - neg.), 23 (Starke Negativbew.)
Therapieangebot	gut, therapeut, therapi, konzept, einzelgesprach, gruppentherapie	8 (Med. Behandlung), 13 (Tagesklinik)

Tabelle 10: Top 21 Themen des Guided BERTopic Modells

ID	Themenbereich (interpretativ)	Beispielwörter	Repräsentatives Zitat (gekürzt)	Anzahl
0	Erfahrungen auf Station	station, stationen, stationär, schwestern, team	Äuf Station auch alle sehr freundlich."	1898
1	Zeitlicher Verlauf (Tage)	tag, tagen, tage, nächsten, ersten	"Vom ersten Tag an [...] sehr wohl gefühlt."	1571
2	Das Krankenhaus (allgemein)	krankenhaus, dieses, ins, kranken- häuser, diesem	"Das Krankenhaus an sich ist schön [...]"	1246
3	Zeitlicher Verlauf (Datum/Jahr)	2024, uhr, 2023, 2025, november	Ich war 2024 in der Klinik."	1225
4	Bewertung (Sterne)	sterne, stern, vergeben, geben, verdient	"0 Sterne./ "Hierfür 5 Sterne!"	972
5	Essen/Verpflegung	essen, abwechslungsreich, geschmeckt, schmackhaft, reichlich	"Das Essen ist überragend!"	741
6	Pflegepersonal & Ärzte (Interaktion)	pflegepersonal, freundlich, ärzte, hilfsbereit, kompetent	"Ärzte und Pflegepersonal super."	733
7	Zeitmanagement (Stunden/Wochen)	stunden, wochen, std, warten, gewartet	"2,5 Stunden./ "Nach 4 Stunden (!)"	682
8	Tagesklinik	tagesklinik, tage, empfehlen, wochen, weiterempfehlen	"Die Tagesklinik ist sehr gut."	666
9	Personal (allgemein)	personal, personals, freundlich, personalmangel, hilfsbereit	"Das Personal ist freundlich [...]"	639
10	Schwestern & Ärzte (Interaktion)	schwestern, schwester, ärzte, nett, hebammen	"Ärzte und Schwestern sind sehr freundlich."	634
12	Zimmer/Ausstattung	zimmer, sauber, eingerichtet, modern, geräumig	"Die Zimmer sind schön.."	576
13	Patientenumgang (Perspektive)	patienten, patient, patientin, anderen, umgang	"Von den anderen Patienten."	526
14	Gefühl: Geholfen worden	geholffen, mir, ibuprofen, weitergeholffen, hat	"Mir hat es sehr geholfen."	512
15	Terminvergabe/-probleme	termin, termine, terminvergabe, bekommen, vereinbaren	"Trotz Termin und Überweisung!!"	501
16	Gefühl: Ernst genommen	genommen, ernst, zeit, fragen, ängste	Ich wurde ernst genommen."	492
17	Starke Negation/Ablehnung	gar, nichts, geht, nicht, sowas	Ich spüre gar nichts."	470
18	Telefonische Erreichbarkeit	telefon, telefonisch, telefonat, ans, erreichen	"[...] niemand geht ans Telefon [...]"	412
19	Mitarbeiter (allgemein)	mitarbeiter, mitarbeiterinnen, mitarbeitern, freundlich, hilfsbereit	Alle Mitarbeiter sind freundlich [...]"	395
20	Schmerzerfahrung/-behandlung	schmerzen, schmerzmittel, starken, bauchschmerzen, schmerzfrei	"Hatte nach OP keine Schmerzen."	391
21	Pfleger/Pflege (Interaktion)	pfleger, pflegerinnen, pflege, pflegerin, pflegeteam	SSehr gute Ärzte, Pflegerinnen und Pfleger [...]"	369

Anmerkung: Das 'Garbage Topic' mit ID -1 (Outliers, 30954 Rez.) und Topic 11, welches außer 'bm' und 'dumm' aus Satzzeichen bestand (588 Rez.) wurden aus der Darstellung entfernt. Sortiert nach Häufigkeit

Tabelle 11: Top 19 Themen des Ein-Sterne-BERTopic Modells

ID	Themenbereich (interpretativ)	Beispielwörter	Repräsentatives Zitat (gekürzt)	Anzahl
0	Patientenumgang (negativ)	patienten, patient, patientin, wird, werden	"[...] Patienten ernst genommen und mit Würde behandelt werden." (Impliziert das Gegenteil)	1202
1	Klinik (allg. Ablehnung)	linik, diese, klinikum, dieser, empfehlen	"Diese Klinik ist nicht zum empfehlen!!!"	960
2	Erfahrungen Station (negativ)	station, stationär, auf, stationen, aufgenommen	SSStation 2 NIE WIEDER."	670
3	Zeitlicher Verlauf (neg. Erfahrung)	tag, tage, tagen, nächsten, am	"Wir sind heute bei Tag 3." (Kontext oft negativ)	537
4	Bewertung (explizit 1 Stern)	stern, sterne, geben, vergeben, verdient	"Man dürfte nicht mal einen Stern geben [...]"	409
5	Krankenhaus (allg. Ablehnung)	krankenhaus, anderes, dieses, krankenhauses, ins	SSehr merkwürdig und das in einem Krankenhaus."	358
6	Behandlung (Kritik)	behandlung, behandelt, behandeln, behandlungen, abgewimmelt	"Die Behandlung an sich ist tückisch [...]"	320
8	Telefonische Erreichbarkeit (negativ)	telefon, telefonisch, ans, am, internet	Es geht keiner ans Telefon."	280
9	Personal (Kritik, Mangel)	personal, personalmangel, personals, unfreundlich, freundlich	"Personal und Arzt sehr unfreundlich."	247
10	Terminprobleme	termin, termine, einen, bekommen, abgesagt	"Mit Termin!" (Impliziert Wartezeit/Problem)	246
11	Diagnose (Fehler, Kritik)	diagnose, diagnosen, diagnostik, diagnostiziert, falsche	"Keine Behandlung und keine Diagnose [...]"	243
12	Medikamente/Med. Versorgung (Kritik)	medikamente, medizinische, medikament, medikamenten, versorgung	"Keine medizinische Versorgung oder Fürsorge."	218
13	Emotionale Reaktion (negativ)	schockiert, schrecklich, traurig, sprachlos, einfach	Einfach nur schrecklich."	210
15	Nicht Gesundwerden/Systemkritik	gesund, gesundheitssystem, gesundheit, gesundheitswesen, unser	"Dort wird man nicht gesund!"	184
16	Mitarbeiter (Kritik)	mitarbeiter, mitarbeiterin, arbeiten, mitarbeitern, arbeit	SSchämen sollten sich die Mitarbeiter."	184
17	Essen (Kritik)	essen, das, kalt, gut, bestellte	"Das Essen wird einfach wieder abgeräumt."	183
18	Geld/Allein gelassen	geld, gelassen, gelegt, gelogen, alleine	älleine gelassen ./ "Hier geht's nur um Geld."	178
19	Ärzte (Kritik)	rztin, arzt, rzte, arztbrief, hr	"[...] den Grünschnabel von Arzt."	176
20	Psychologen (Kritik)	psychologin, psychologen, psychologe, psychologische, psychotherapie	SSolche sind keine Psychologen."	163
21	Allgemeine starke Abwertung	alles, aller, allem, sau, unter	Älles in allem: Unter aller Patientenwürde."	150

Anmerkung: Das 'Garbage Topic' mit ID -1 (Outliers, 8190 Rez.) und Topic 14, welches neben 'horror' und 'dumm' ausschließlich Satzzeichen enthielt (200 Rez.) wurden nicht abgebildet. Die Auswahl umfasst die 19 häufigsten verbleibenden Topics. Sortiert nach Häufigkeit.

B Weiteres Material

EIGENSTÄNDIGKEITSERKLÄRUNG